架構重建卡 13 **數據的線性變換** 標準版 牛夫子·高中數學｜學測（數A：高一下數據分析）

對照用：逐格圈 ✓對 ▵漏 ✗錯 ?不會

一維數據統計量與線性變換 $y_i = ax_i + b$（n 是筆數、x_i 是原數據、y_i 是變換後數據、a, b 是常數且 $a \neq 0$；μ_X, μ_Y 是平均數、σ_X, σ_Y 是母體標準差、Q_1, Q_3 是第 1、第 3 四分位數、z_i 是標準化數據、Z 是標準化後的變數）

	定義與算式	平移 $+b$ 與伸縮 $\times a$ 後變成什麼	幾何意義與何時用	降成 / 數值例 / 地圖
① 集中量數（算術平均數 μ_X、中位數、眾數）	算術平均數 $\mu_X = \frac{1}{n}\sum_{i=1}^{n} x_i$；中位數是數據由小到大排正中間的數（偶數筆取中間兩筆平均）；眾數是出現最多次的數	位置跟著一起搬：$\mu_Y = a\mu_X + b$；中位數與眾數也都變成原來的 a 倍加 b	μ_X 是數據的重心（離均差總和 $\sum(x_i - \mu_X) = 0$，且在所有實數 c 中，$c = \mu_X$ 使 $\sum(x_i - c)^2$ 最小）；但極端值（離群值）會大幅拉偏平均數，此時改用中位數代表典型水準	例：數據 $2, 4, 6, 8, 10$ 的平均數 $\mu_X \Longrightarrow 6$ 例：若 $\mu_X = 60$，線性調整 $y_i = 1.2x_i + 10$ 後的新平均數 $\mu_Y \Longrightarrow 82$ 地圖：集中量數、線性變換的影響、百分位數與四分位數
② 全距與四分位距（$Q_3 - Q_1$）	全距 = 最大值減最小值；四分位距 = $Q_3 - Q_1$（中間 50% 數據的跨度）	兩數相減時 $+b$ 互相抵消，且差距必為非負：新全距 $= \lvert a \rvert \times$ 原全距；新四分位距 $= \lvert a \rvert (Q_3 - Q_1)$（注意 $a < 0$ 時大小順序顛倒：新最大值是 $ax_{\min} + b$，新 Q_1 是 $aQ_3 + b$，所以相減後仍為正）	四分位距不受頭尾極端值影響，常搭配中位數畫盒狀圖	↪ 降成 ①：因為最大值與最小值都照①變成 $ax_{\max} + b$ 與 $ax_{\min} + b$，相減取絕對值就把 $+b$ 消掉了 例：原數據四分位距為 15，經 $y_i = -2x_i + 100$ 變換後的新四分位距 $\Longrightarrow 30$ 地圖：百分位數與四分位數、線性變換的影響
③ 標準差 σ_X 與變異數 σ_X^2	$\sigma_X = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i - \mu_X)^2} = \sqrt{\left(\frac{1}{n}\sum_{i=1}^{n} x_i^2\right) - \mu_X^2}$（平方的平均減去平均的平方，再開根號）	離均差 $y_i - \mu_Y = a(x_i - \mu_X)$，平移 $+b$ 完全抵消：新標準差 $\sigma_Y = \lvert a \rvert \sigma_X$；新變異數 $\sigma_Y^2 = a^2\sigma_X^2$	衡量數據離平均數有多分散；全部數據同加一個常數 b 時，分散程度不變；展開式 $\frac{1}{n}\sum x_i^2 - \mu_X^2$ 在已知平方和求標準差（或反求平方和）時最快	↪ 降成 ①：由①得 $y_i - \mu_Y = (ax_i + b) - (a\mu_X + b) = a(x_i - \mu_X)$，平方平均再開根號即提出 $\sqrt{a^2} = \lvert a \rvert$ 例：數據 $2, 4, 6, 8, 10$ 的母體標準差 $\sigma_X \Longrightarrow 2\sqrt{2}$ 例：若 $\sigma_X = 5$，經 $y_i = -3x_i + 20$ 變換後的新標準差 $\sigma_Y \Longrightarrow 15$ 地圖：標準差、線性變換的影響
④ 標準化數據（z 分數）	當 $\sigma_X > 0$ 時，$z_i = \frac{x_i - \mu_X}{\sigma_X}$（它本身就是一個線性變換：乘 $\frac{1}{\sigma_X}$ 再加 $-\frac{\mu_X}{\sigma_X}$）	不論原數據為何，標準化後的數據永遠滿足：平均數 $\mu_Z = 0$、標準差 $\sigma_Z = 1$；若先對 x_i 做線性變換 $y_i = ax_i + b$ 再標準化，當 $a > 0$ 時 y_i 的標準化數據和 x_i 的完全相同，當 $a < 0$ 時變成 $-z_i$	把不同科目的單位與底分消掉，用來比較「某生在國文與數學哪一科在班上的相對表現較好」（看誰的 z 分數高）	↪ 降成 ①、③：先減 μ_X 把平均數移到 0（①），再除以 σ_X 把標準差縮成 1（③） 例：某生考 78 分，班平均 66 分、標準差 8 分，求其標準化數據 $z \Longrightarrow \frac{3}{2}$ 地圖：標準化（z 分數）

背面　二維數據：相關係數與最適直線（x_i, y_i 是原數據、u_i, v_i 是變換後數據、μ_X, μ_Y 是平均數、$\sigma_X, \sigma_Y, \sigma_U, \sigma_V$ 是標準差、$z_{x,i}, z_{y,i}$ 是標準化數據、r 是相關係數、m 是迴歸斜率、a, b, c, d 是常數，$ac \neq 0$）

	公式與範圍	對 x_i, y_i 做線性變換 $u_i = ax_i + b$、$v_i = cy_i + d$ 後怎麼變	關鍵性質與常見陷阱	降成 / 數值例 / 地圖
⑤ 相關係數 r	$r = \dfrac{\sum(x_i - \mu_X)(y_i - \mu_Y)}{n\sigma_X\sigma_Y} = \dfrac{1}{n}\sum z_{x,i}z_{y,i}$（$z_{x,i}$、$z_{y,i}$ 分別是 x_i、y_i 的標準化數據，兩者乘積的平均）；恆滿足 $-1 \le r \le 1$	平移 $+b, +d$ 與放大縮小倍率都不改變相關強弱，只看 a 與 c 同號或異號：當 $ac > 0$ 時新相關係數 $= r$；當 $ac < 0$ 時新相關係數 $= -r$	$\lvert r\rvert = 1$ 代表所有點完全落在同一條非水平非鉛直的直線上（斜率 > 0 則 $r = 1$，斜率 < 0 則 $r = -1$）；若所有點排在水平線上（$\sigma_Y = 0$）或鉛直線上（$\sigma_X = 0$），分母為 0，相關係數無定義	↪ 降成 ④、③：由④，u_i 的標準化數據是 $\pm z_{x,i}$（$a > 0$ 取 $+$、$a < 0$ 取 $-$），v_i 的同理看 c；相乘後只差一個正負號，由 ac 的正負決定 例：X, Y 的相關係數 $r = 0.8$，求 $U = 2X - 5$ 與 $V = -3Y + 1$ 的相關係數 $\Longrightarrow -0.8$ 例：三點 $(1,3)$、$(2,5)$、$(4,9)$ 的相關係數 $r \Longrightarrow 1$（三點共線且斜率 $2 > 0$） 地圖：相關係數、散布圖與離群值
⑥ 最適直線（最小平方法迴歸直線）	Y 對 X 的最適直線必過重心 (μ_X, μ_Y)，方程式為 $y - \mu_Y = m(x - \mu_X)$，其中斜率 $m = r\dfrac{\sigma_Y}{\sigma_X} = \dfrac{\sum(x_i - \mu_X)(y_i - \mu_Y)}{\sum(x_i - \mu_X)^2}$	新的最適直線（V 對 U）可直接把原直線裡的 x, y 代換成 $\dfrac{u-b}{a}$ 與 $\dfrac{v-d}{c}$；新斜率 $= \dfrac{c}{a}m$（只變 x 時是 $\dfrac{m}{a}$、只變 y 時是 cm；因為 $\sigma_V = \lvert c\rvert\sigma_Y$、$\sigma_U = \lvert a\rvert\sigma_X$，配⑤的正負號恰好消掉絕對值）	斜率 m 與相關係數 r 必同號（因 $\sigma_X, \sigma_Y > 0$）；注意「Y 對 X 的迴歸直線」與「X 對 Y 的迴歸直線」在 $\lvert r\rvert \neq 1$ 時是兩條不同的直線，但一定交於重心 (μ_X, μ_Y)	↪ 降成 ①、③、⑤：把數據標準化後最適直線是 $z_y = rz_x$，將④的 $z_y = \dfrac{y-\mu_Y}{\sigma_Y}$、$z_x = \dfrac{x-\mu_X}{\sigma_X}$ 代回即得 $y - \mu_Y = r\dfrac{\sigma_Y}{\sigma_X}(x - \mu_X)$ 例：$\mu_X = 4$、$\mu_Y = 10$、$\sigma_X = 2$、$\sigma_Y = 5$、$r = 0.6$，求 Y 對 X 的最適直線在 $x = 8$ 的預測值 $\Longrightarrow 16$ 地圖：最適直線

收尾題

收尾 1　整理線性變換 $y_i = ax_i + b$（$a \neq 0$）：哪些量「乘 a 加 b」？哪些量「只乘 $|a|$」？哪些量「只乘 a^2」？哪些量「大小完全不變（只看正負號）」？

① 乘 a 加 b：平均數、中位數、眾數；各百分位數與四分位數也是，但 $a < 0$ 時位置顛倒（新 $Q_1 = aQ_3 + b$、新 $Q_3 = aQ_1 + b$）；② 只乘 $|a|$：全距、四分位距、標準差；③ 只乘 a^2：變異數；④ 大小不變、只看正負號：標準化數據 z_i（$a < 0$ 變號）與相關係數 r（$ac < 0$ 變號）。

收尾 2　某班數學與物理成績的最適直線斜率是 $m = 1.6$，能不能說兩科的相關係數 $r = 1.6$？斜率 m 和相關係數 r 差在哪裡？

絕對不行，因為相關係數恆滿足 $-1 \le r \le 1$！斜率 $m = r\dfrac{\sigma_Y}{\sigma_X}$ 還乘上了兩科標準差的比值 $\dfrac{\sigma_Y}{\sigma_X}$（有單位比例），只能確定 m 和 r 的正負號相同（$m = 1.6 > 0$ 代表正相關 $r > 0$，且由 $|r| \le 1$ 可知 $\dfrac{\sigma_Y}{\sigma_X} \ge 1.6$），要知道 σ_X, σ_Y 才能算出 r。

常見的漏和錯

1. 當 $a < 0$ 時，標準差寫成 $a\sigma_X$（忘了加絕對值 $|a|$，標準差永遠 ≥ 0）。
2. 以為把數據同加 10 分，標準差也會加 10：平移不改變分散程度，標準差不變。
3. 變異數 σ_Y^2 只乘了 $|a|$ 而忘了平方成 $a^2\sigma_X^2$。
4. 以為相關係數 r 越大，最適直線就越陡：r 衡量的是點貼近直線的集中程度，哪怕所有點共線在 $y = 0.01x$ 上很平緩，r 依然是 1。
5. 預測值代最適直線時忘了直線必過重心 (μ_X, μ_Y)：若題目給 $y = mx + k$ 與 μ_X，直接代 $\mu_Y = m\mu_X + k$ 就能求出 μ_Y。

每格的數值例都經 `_scripts/frame_cards/verify_frames.py` 兩條路驗算。「地圖」列出工具地圖上對應的工具。